

# Trabajo Práctico 1

## Métodos Numéricos


Departamento de Computación  
Facultad de Ciencias Exactas y Naturales  
Universidad de Buenos Aires

22 de mayo de 2013

# Estimando parámetros de distribuciones

- ▶ Sea  $x_1, x_2, \dots, x_n$  una secuencia de  $n$  datos, con  $x_i \in \mathbb{R}$
- ▶ Provienen de una distribución de la cual no sabemos los parámetros



Histograma:



# Estimando parámetros de distribuciones

## Histograma

► datos = [1 2 3 2 3 2 1 2 3 4 3 3 3]



# Estimando parámetros de distribuciones

## Distribución $\Gamma$ Generalizada


$$f_{\Theta}(x) = \frac{\beta x^{\beta\lambda-1}}{\sigma^{\beta\lambda} \Gamma(\lambda)} \exp\left\{-\left(\frac{x}{\sigma}\right)^{\beta}\right\} \quad \text{con } x \in \mathbb{R}_{>0}$$

donde

- ▶  $\Gamma(\cdot)$  función Gamma definida como  $\Gamma(z) = \int_0^\infty t^{z-1} e^{-t} dt$
- ▶  $\Theta$  representa a la tupla de parámetros  $\Theta = (\sigma, \beta, \lambda)$


# Estimando parámetros de distribuciones

Distribución  $\Gamma$  Generalizada:  $f_{\Theta}(x) = \frac{\beta x^{\beta\lambda-1}}{\sigma^{\beta\lambda} \Gamma(\lambda)} \exp\left\{-\left(\frac{x}{\sigma}\right)^{\beta}\right\}$




# Estimando parámetros de distribuciones

Distribución  $\Gamma$  Generalizada:  $f_{\Theta}(x) = \frac{\beta x^{\beta\lambda-1}}{\sigma^{\beta\lambda} \Gamma(\lambda)} \exp\left\{-\left(\frac{x}{\sigma}\right)^{\beta}\right\}$




# Estimando parámetros de distribuciones

Distribución  $\Gamma$  Generalizada:  $f_{\Theta}(x) = \frac{\beta x^{\beta\lambda-1}}{\sigma^{\beta\lambda} \Gamma(\lambda)} \exp\left\{-\left(\frac{x}{\sigma}\right)^{\beta}\right\}$



# Ejemplo de Aplicación

Recuperando imágenes de texturas en bases de datos



# Ejemplo de Aplicación

Recuperando imágenes de texturas en bases de datos

## Problema




Dada una textura cualquiera, cuáles son las más parecidas en la base de datos?

# Ejemplo de Aplicación

Recuperando imágenes de texturas en bases de datos

## Modelado de datos

- ▶ Los datos *transformados* de las texturas tienen una distribución similar a una  $\Gamma G$



# Ejemplo de Aplicación

Recuperando imágenes de texturas en bases de datos

## Modelado y recuperación de datos

- ▶ Las texturas se representan usando sólo los parámetros de la ΓD
- ▶ Se estiman distancias entre texturas a partir de las distribuciones que las modelan.
- ▶ Se logra una recuperación mayor al 95% !

# Recordando un poco de *Proba*

## Estimadores de máxima verosimilitud

Queremos estimar parámetros  $\Theta$  de distribución  $f_\Theta$  a partir de datos  $x_1, \dots, x_n$

- ▶ Función de densidad conjunta con muestras i.i.d.:  
$$f(x_1, \dots, x_n | \Theta) = f(x_1 | \Theta) \times \dots \times f(x_n | \Theta)$$
- ▶ Construyo función de verosimilitud en función de los parámetros:  $L(\Theta | x_1, \dots, x_n) = f(x_1, \dots, x_n | \Theta)$
- ▶  $\log(L(\Theta | x_1, \dots, x_n)) = \sum_{i=1}^n \log f(x_i | \Theta)$
- ▶ Buscamos el valor de  $\Theta$  que maximiza  $\log(L(\Theta | x_1, \dots, x_n))$
- ▶ En nuestro caso:  $\frac{\partial L(\Theta | X)}{\partial \sigma} = \frac{\partial L(\Theta | X)}{\partial \beta} = \frac{\partial L(\Theta | X)}{\partial \lambda} = 0$

# Recordando un poco de *Proba*

## Estimadores de máxima verosimilitud

Para la distribución  $\Gamma$  Generalizada, los estimadores de máxima verosimilitud deben cumplir:

$$\begin{aligned}\tilde{\sigma} &= \left( \frac{\sum_{i=1}^n x_i^{\tilde{\beta}}}{n\tilde{\lambda}} \right)^{1/\tilde{\beta}} \\ \tilde{\lambda} &= \left[ \tilde{\beta} \left( \frac{\sum_{i=1}^n x_i^{\tilde{\beta}} \log x_i}{\sum_{i=1}^n x_i^{\tilde{\beta}}} - \frac{\sum_{i=1}^n \log x_i}{n} \right) \right]^{-1} \\ 0 &= \frac{\tilde{\beta}}{n} \sum_{i=1}^n \log x_i - \log \sum_{i=1}^n x_i^{\tilde{\beta}} + \log(n\tilde{\lambda}) - \psi(\tilde{\lambda})\end{aligned}$$

# Recordando un poco de *Proba*

## *Momentos* de una variable aleatoria

- ▶ Momento de orden  $n$ :  $E[X^n]$
- ▶ Momentos de diferentes órdenes están relacionados con la media, varianza, skewness (asimetría), curtosis, etc.
- ▶ Estimando los dos primeros momentos de una v.a. con distribución  $\Gamma$  Generalizada, se derivan las sig. ecuaciones:

$$\log(\mathcal{M}(2\beta)) - 2 \log(\mathcal{M}(\beta)) = \log(1 + \beta(\mathcal{R}(\beta) - \mathcal{R}(0)))$$

$$\frac{\mathcal{M}(2\beta)}{\mathcal{M}^2(\beta)} = 1 + \beta(\mathcal{R}(\beta) - \mathcal{R}(0))$$

donde  $\mathcal{M}$  y  $\mathcal{R}$  se calculan a partir de los datos  $x_1, \dots, x_n$ :

$$\mathcal{M}(s) = \frac{1}{n} \sum_{i=1}^n x_i^s, \quad \widehat{\mathcal{M}}(s) = \frac{1}{n} \sum_{i=1}^n x_i^s \log(x_i),$$

$$\mathcal{R}(s) = \frac{\widehat{\mathcal{M}}(s)}{\mathcal{M}(s)}$$

## Recapitulando...

Para estimar los parámetros en el TP:

1. Estimamos  $\tilde{\beta}$  resolviendo cualquiera de las sig. 2 ecuaciones:

$$\log(\mathcal{M}(2\beta)) - 2 \log(\mathcal{M}(\beta)) = \log(1 + \beta(\mathcal{R}(\beta) - \mathcal{R}(0)))$$

$$\frac{\mathcal{M}(2\beta)}{\mathcal{M}^2(\beta)} = 1 + \beta(\mathcal{R}(\beta) - \mathcal{R}(0))$$

2. Una vez estimado  $\tilde{\beta}$ , despejando de:

$$\tilde{\sigma} = \left( \frac{\sum_{i=1}^n x_i^{\tilde{\beta}}}{n \tilde{\lambda}} \right)^{1/\tilde{\beta}}$$

$$\tilde{\lambda} = \left[ \tilde{\beta} \left( \frac{\sum_{i=1}^n x_i^{\tilde{\beta}} \log x_i}{\sum_{i=1}^n x_i^{\tilde{\beta}}} - \frac{\sum_{i=1}^n \log x_i}{n} \right) \right]^{-1}$$

estimamos los restantes parámetros  $\tilde{\sigma}$  y  $\tilde{\lambda}$ .

# Finalizando...

## Matlab

- ▶ Leer `matlab.pdf` en la sección recursos de la web
- ▶ Usar `leer_datos.m` para cargar los datos en Matlab
- ▶ `dibujarHistyAjuste.m` como ayuda para el ítem 4 del TP

## Informe TP

- ▶ Leer `pautas.pdf` en la sección downloads de la web
- ▶ Seguir los lineamientos allí descriptos para el informe
- ▶ También: `TPCheklist.pdf`